

郭晨杰

男 | 26岁 | 籍贯: 吉安 | 17679163910 | 17679163910@163.com
3年工作经验 | 大模型开发工程师



专业技能

精通 vLLM、SGLang 等推理框架，利用 PagedAttention 与量化技术实现高并发、低延迟的本地化部署服务
熟练使用市面上的ai编程工具高效完成代码编写，如openclaw、claude code等
熟练运用 LangChain/LangGraph 及 Dify/n8n，设计含 Memory 机制与 Function Call/MCP 的智能体 workflow
掌握基于 ES/FAISS/Milvus 的检索增强生成系统，涵盖数据清洗、分块、混合检索、重排序及效果评估全流程
熟悉 RAG 端到端架构设计与优化，涵盖数据预处理、文档分段、向量检索、重排序及效果评估全链路
熟练运用 DeepSpeed+LoRA/QLoRA 进行高效微调，具备 DPO/GRPO 对齐及 FastAPI 端到端落地能力
能自主设计并实现 Agent 工作流，熟悉多智能体编排与自动化任务流程构建。
拥有 NLP 模型压缩与部署实战经验，熟练应用量化、知识蒸馏与结构剪枝等技术提升推理效率
具备从零搭建与优化 Transformer 模型的能力，深入理解注意力机制及其在 NLP 中的应用
熟练使用 Python 及 Pandas、NumPy 等工具，完成训练数据清洗、特征工程与分析
熟悉深度学习基础，能设计并实现 ANN、CNN、RNN 等经典神经网络架构

项目经历

乙女游戏AI对话系统

2025.06-2026.01

项目背景:

传统乙女游戏剧情固定、交互有限，为增强用户的使用体验，在游戏中新增ai智能对话，实现动态、拟人化、长期记忆的虚拟角色对话体验。

技术栈:

LangChain、LangGraph、RAG、Milvus、Redis、vLLM、FastAPI

主要职责:

基于LangGraph设计带状态切换的对话流程，如识别用户充值意图后自动触发二次确认，用户确认后跳转至充值界面
设计基于 LangChain 的混合记忆架构，实现持久化记忆力以及上下文管理，让用户能够体验到真正跟人对话的感觉
设计基于Milvus向量数据库的知识库和基于Redis的缓存数据库
整合业界资料以及多方面资料，基于Milvus构建关键字、向量混合检索，使用BGE-Reranker进行精排序
用 LoRA 微调 Qwen3-14B，专门强化角色语气和情感表达
使用FastAPI+vLLM部署高性能服务，再基于Redis缓存数据库提升响应速度以及用户体验

项目成果:

用户使用体验显著提升，留存率约提升30%，微调后OOC（人设崩坏）情况减少约 22%，用户对话轮次相较于规则类的高17%

“星轨” 智能游戏辅助助手

2025.01-2025.07

项目背景:

传统游戏攻略分散、连招学习门槛高、新手上手困难。为提升玩家体验，为此设计辅助助手，实现动态攻略推荐、实时操作反馈，打造“随叫随到”的私人游戏教练。

技术栈:

RAG、LoRA、BGE-M3、vLLM、FastAPI、BGE-Reranker-v2-m3

主要职责:

构建量化的游戏攻略，整合每次对话选项所决定的剧情走向、要点以及结局简介

基于Milvus设计混合检索，检索后基于BGE-Reranker进行排序，使得回复准确度提升越20%

植入Redis缓存数据库，使经常出现的问题能够更迅速的回复

基于LoRA针对一款游戏进行微调，以增强其对单独某款游戏的攻略推荐精准度以及个性化提供建议

基于 vLLM 与 FastAPI 实现高吞吐、低延迟的大模型服务化部署

项目成果：

使用向量检索，预防搜索时出现错别字导致检索不准确的情况，用户查攻略的时间减少约60%

“星图” 智能知识助手

2024.07-2024.12

项目背景：

针对公司内部文档分散、新人上手慢、重复咨询成本高的问题，搭建了一个私有化部署的AI助手，主要通过RAG技术实现对公司数据的精准问答

技术栈：

LangChain、Milvus、Sparse Vector、BGM-M3

主要职责：

基于 LangChain构建智能体工作流，实现复杂问题的需求解析、任务分解以及工具调用

基于 Milvus的Sparse Vector和BGM-M3进行关键词和向量的检索，再根据BGE-Reranker进行排序后生成回复

使用FastAPI开发高并发异步后端服务，提供企业项目进度查询 、结果回调等接口

使用Redis缓存员工对话，提升员工使用时的响应速度，并且使得模型能够具有记忆性

项目成果：

使新员工能够更加快速的了解公司基本流程部门，提升员工的归属感

工作经历

北京月壤科技有限公司 算法工程师

2023.03-2026.02

主导基于 vLLM 与 RAG 架构的高性能智能对话系统研发，实现低延迟、高精度的领域知识问答。

搭建 LangChain+Milvus 检索系统，优化分块与重排序策略，结合评估链路解决模型幻觉。

设计多智能体协作工作流，集成外部工具实现复杂任务自动规划与执行，提升业务自动化率。

负责垂直领域大模型的微调工作，制定微调策略，提升模型在特定任务中的表现

研究并应用检索增强生成(RAG)、提示词工程等技术提升模型效果

教育经历

江西理工大学 本科 软件工程

2019-2023